# HOTEL REVIEWS DATA ANALYSIS REPORT

Analysis of Customer Reviews
and Hotel Performance

CUSTOMER REVIEWS | DATA ANALYSIS | PERFORMANCE INSIGHTS | TRENDS | QUALITY EXPERIENCE

**Antonella Ferorelli**

Data Analysis Project

Maggio 2026

Indice

**1 INTRODUZIONE** ..... 3

**2. METODOLOGIA** ..... 5

2.1 Pulizia e preparazione del dataset ..... 5

2.2 Creazione del database relazionale ..... 6

2.3 Pipeline di caricamento dei dati in SQL ..... 7

..... 7

2.4 Verifica del caricamento e controllo delle tabelle ..... 9

2.5 Analisi tramite query SQL ..... 10

**3. RISULTATI DELL'ANALISI** ..... 12

3.1 Andamento temporale delle recensioni ..... 12

3.2 Nazionalità dei recensori ..... 14

3.3 Performance città e hotel ..... 16

3.4 Correlazione score e lunghezza ..... 19

**4. CONCLUSIONI** ..... 23

4.1 Consigli operativi per il cliente ..... 24

4.2 Limiti all'analisi ..... 25

# 1 INTRODUZIONE

Il presente report finale, ha l'obiettivo di analizzare un dataset di recensioni alberghiere provenienti da Booking.com, relativo a hotel di lusso situati in diverse città europee. Il dataset originale contiene oltre 515.000 recensioni e comprende informazioni relative agli hotel, ai recensori, ai punteggi assegnati, ai testi delle recensioni positive e negative, alla nazionalità degli utenti e alla posizione geografica delle strutture.

L'analisi è stata sviluppata seguendo un processo end-to-end di data analysis: importazione del dataset, esplorazione iniziale, pulizia dei dati, costruzione di un database relazionale SQL, interrogazione dei dati tramite query, analisi con pandas e realizzazione di visualizzazioni con Matplotlib. L'obiettivo finale è individuare pattern utili per comprendere il comportamento dei recensori, le differenze tra città e nazionalità, e le relazioni tra punteggi e caratteristiche delle recensioni.

Il progetto risponde alle richieste dell'elaborato, che prevedono l'utilizzo congiunto di Python, pandas, SQL e visualizzazioni con Matplotlib per produrre un report strutturato e orientato all'interpretazione dei risultati.

L'obiettivo principale del progetto è analizzare le recensioni degli hotel europei per ricavare informazioni utili sul livello di soddisfazione dei clienti e sulle performance delle strutture.

In particolare, l'analisi mira a rispondere alle seguenti domande su come si distribuiscono le recensioni nel tempo, quali sono le nazionalità che recensiscono di più, se i recensori del Regno Unito assegnano punteggi diversi rispetto agli altri utenti; quali città concentrano il maggior numero di recensioni; quali città presentano lo score medio più elevato; se esiste una relazione tra la lunghezza della recensione e il punteggio assegnato e infine, quali variabili numeriche risultano maggiormente correlate tra loro.

Il dataset utilizzato è Hotel_Reviews.csv, disponibile su Kaggle, e contiene recensioni reali relative a hotel europei pubblicate su Booking.com. Secondo le istruzioni del progetto, il dataset comprende circa 515.000 recensioni e 1.493 hotel di lusso in Europa, nel periodo 2015-2017.

Dopo le operazioni di pulizia, il dataset finale utilizzato per le analisi contiene 511.944 recensioni. Nel file di pulizia risultano inoltre create variabili derivate come Review_Year, Review_Month, stay_nights e total_review_length, utilizzate nelle analisi successive.

# 2. METODOLOGIA

## 2.1 Pulizia e preparazione del dataset

La prima fase del lavoro è stata svolta in Python tramite la libreria pandas. Il dataset è stato caricato in un dataframe e analizzato attraverso funzioni di esplorazione come info(), shape, dtypes, describe() e il controllo dei valori mancanti.

Durante questa fase sono state effettuate le seguenti operazioni:

1. controllo delle dimensioni del dataset;
2. verifica dei tipi di dato;
3. analisi dei valori mancanti;
4. conversione della colonna Review_Date in formato datetime[1];
5. estrazione di anno e mese della recensione;
6. rimozione dei duplicati;
7. creazione di variabili derivate, come la lunghezza totale della recensione;
8. salvataggio del dataset pulito come hotel_reviews_clean.csv.

Successivamente sono stati rimossi i duplicati esatti, così che ogni riga rappresentasse una recensione unica. Dopo la rimozione dei valori mancanti, il controllo finale ha mostrato l'assenza di valori nulli nelle principali colonne del dataset.

Il controllo iniziale ha mostrato che il dataset originale conteneva 515.738 osservazioni e 17 variabili. I valori mancanti erano concentrati soprattutto nelle variabili geografiche lat e lng, mentre le altre colonne principali risultavano complete.

Al termine della pulizia, il dataframe è stato esportato nel file hotel_reviews_clean.csv, utilizzato come base per la fase successiva di caricamento nel database SQL.

[1] La conversione della data ha permesso di creare le variabili Review_Year e Review_Month, necessarie per analizzare l'andamento delle recensioni nel tempo.

## 2.2 Creazione del database relazionale

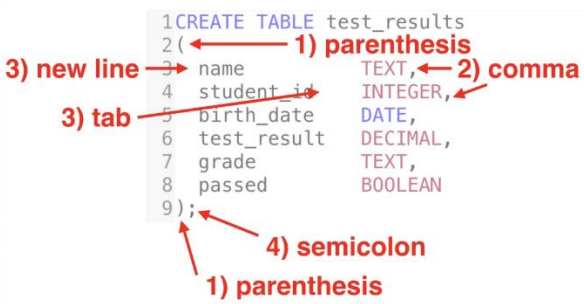


Dopo aver ottenuto il dataset pulito, è stata progettata la struttura del database relazionale tramite il file CREATE_TABLE.sql. L'obiettivo di questa fase era organizzare i dati in più tabelle collegate tra loro. La scelta di usare chiavi primarie e chiavi esterne è stata fondamentale per mantenere la coerenza del database. Le chiavi primarie infatti, identificano in modo univoco ogni record all'interno di una tabella, mentre le chiavi esterne permettono di creare collegamenti tra tabelle diverse.

Per creare questa operazione, è stato opportuno **effettuare la creazione di quattro tabelle** principali dunque creare quattro entità distinte: hotel; hotel_stats; reviewers; reviews.

La tabella **hotels** contiene le informazioni principali relative agli hotel. In questa tabella sono stati inseriti attributi quali il nome dell'hotel, l'indirizzo e le coordinate geografiche, cioè latitudine e longitudine. Ogni hotel è identificato da una chiave primaria chiamata hotel_id. Inserendo invece gli hotel in una tabella separata, ogni struttura viene registrata una sola volta e può essere collegata alle sue recensioni tramite l'identificativo hotel_id.

Nella tabella **hotel_stats**, sono stati inseriti il punteggio medio dell'hotel, il numero totale di recensioni e il numero aggiuntivo di valutazioni ricevute. Questa tabella è collegata alla tabella hotels tramite la chiave esterna hotel_id.

La tabella **reviewers** contiene le informazioni relative ai recensori. In particolare, sono state considerate: la nazionalità del recensore e il numero totale di recensioni che il recensore aveva già fornito.

La tabella **reviews** rappresenta la tabella centrale del database, perché contiene le singole recensioni. In questa tabella sono stati inseriti i dati relativi alla recensione come la data, il punteggio assegnato dal recensore, il testo della recensione positiva e negativa, il numero di parole positive e negative, i tag e la durata del soggiorno.

## 2.3 Pipeline di caricamento dei dati in SQL

In questa fase, è stata realizzata una **pipeline**[2] di caricamento dati in Python, all'interno del notebook INSERT DATA.ipynb.

Questa fase ha avuto l'obiettivo di trasferire i dati dal file pulito hotel_reviews_clean.csv alle tabelle SQL create in precedenza.

Il caricamento non è stato effettuato direttamente dal file CSV al database, ma tramite Python. Questa scelta ha permesso di preparare separatamente i dataframe corrispondenti alle diverse tabelle del database, controllare la coerenza dei dati e associare correttamente gli identificativi necessari, come hotel_id e reviewer_id.

[2] Una pipeline di dati racchiude le modalità con cui i dati fluiscono da un sistema all'altro. Consiste in una serie di fasi che vengono eseguite in un ordine specifico e in cui l'output di una fase funge da input per la fase successiva.

Per prima cosa è stata creata la connessione al database SQL utilizzando SQLAlchemy[3]. Per farlo, si rende dunque necessario installare la libreria SQLAlchemy.

Attraverso la funzione create_engine()[4] è stato possibile collegare Python al database MariaDB/MySQL e utilizzare pandas per inviare i dati alle tabelle.

Successivamente, il file hotel_reviews_clean.csv è stato importato in un dataframe pandas. Da questo dataframe principale sono stati ricavati dataframe separati per ciascuna tabella del database: hotels, hotel_stats, reviewers e reviews.

Per la tabella hotels sono state selezionate le colonne relative al nome dell'hotel, all'indirizzo e alle coordinate geografiche. Poiché nel dataset ogni hotel compariva più volte, una per ogni recensione ricevuta, sono stati rimossi i duplicati, ottenendo una sola riga per ciascuna struttura. Dopo questa preparazione, i dati sono stati caricati nella tabella SQL hotels.

Per la tabella hotel_stats sono state selezionate le informazioni statistiche relative agli hotel, come il punteggio medio, il numero totale di recensioni e il numero aggiuntivo di valutazioni. Questa tabella è stata collegata alla tabella hotels tramite l'identificativo hotel_id, in modo da associare ogni gruppo di statistiche al rispettivo hotel.

Per la tabella reviewers sono state considerate la nazionalità del recensore e il numero totale di recensioni che il recensore aveva già fornito. Poiché il dataset originale non conteneva un identificativo univoco del recensore, è stato creato un identificativo progressivo reviewer_id, utile per collegare i recensori alle recensioni.

La tabella reviews è stata costruita come tabella principale dell'analisi. In questa fase sono stati inseriti i dati relativi alle singole recensioni, tra cui la data, l'anno, il mese,

[3] SQLAlchemy, è una libreria Python che mette a disposizione un toolkit SQL (chiamato "SQLAlchemy Core") e un Object Relational Mapper (ORM) che permette di interagire con un database SQL, utilizzando il codice Python, anziché attraverso query SQL. Le tabelle del database vengono trasformate in classi Python e le righe in oggetti.
[4] L'engine gestisce la connessione al database ed esegue le query SQL.

il punteggio assegnato, le componenti testuali positiva e negativa, i conteggi delle parole, i tag, la durata del soggiorno e la lunghezza totale della recensione.

Prima del caricamento finale, la tabella reviews è stata arricchita con le chiavi esterne hotel_id e reviewer_id. Questi identificativi sono stati recuperati **tramite operazioni di merge**[5] tra il dataframe principale e le tabelle hotels e reviewers. In questo modo, ogni recensione è stata collegata correttamente sia all'hotel recensito sia al relativo recensore.

Infine, i dataframe sono stati caricati nel database tramite il **metodo to_sql()** di pandas. Per la tabella reviews, composta da oltre 500.000 righe, è stato utilizzato il parametro chunksize[6].

La pipeline ha quindi permesso di trasformare il dataset pulito in un database relazionale popolato e pronto per le successive query di analisi.

## 2.4 Verifica del caricamento e controllo delle tabelle

Dopo aver completato la pipeline di caricamento, sono state eseguite alcune **verifiche sul database per controllare che i dati fossero stati inseriti correttamente** nelle tabelle SQL.

Questa fase è stata necessaria per assicurarsi che il passaggio da Python a SQL fosse avvenuto senza errori e che le relazioni tra le tabelle fossero coerenti. In particolare, sono stati controllati il numero di righe presenti in ciascuna tabella, la presenza delle chiavi primarie e il corretto collegamento tra le tabelle tramite le chiavi esterne.

Le principali verifiche effettuate sono state:

[5] La funzione DataFrame.merge() di Pandas serve a unire due DataFrame utilizzando chiavi condivise (keys). In questo modo è possibile combinare in modo efficiente i dati provenienti da diverse fonti per eseguire analisi più complete.
[6] Consente di dividere il caricamento in blocchi più piccoli. Questo accorgimento rende il processo più stabile e riduce il rischio di errori durante l'inserimento dei dati.

1. conteggio delle righe nella tabella hotels;

2. conteggio delle righe nella tabella hotel_stats;

3. conteggio delle righe nella tabella reviewers;

4. conteggio delle righe nella tabella reviews;

5. controllo del collegamento tra hotels e reviews;

6. controllo della distribuzione dei punteggi per nazionalità.

**Il conteggio delle righe ha permesso di verificare che ogni tabella contenesse il numero di record atteso**. In particolare, la tabella reviews contiene il maggior numero di osservazioni, poiché ogni riga rappresenta una singola recensione. Le tabelle hotels, hotel_stats e reviewers, invece, contengono informazioni più sintetiche e quindi un numero inferiore di righe.

Successivamente è stato verificato il join tra la tabella hotels e la tabella reviews. Questo controllo è stato importante perché ha permesso di accertare che ogni recensione fosse correttamente collegata al relativo hotel tramite la chiave hotel_id.

**Il controllo delle relazioni tra le tabelle ha confermato che il database era stato popolato correttamente** e che poteva essere utilizzato per le successive analisi SQL.

## 2.5 Analisi tramite query SQL

Dopo aver verificato il corretto caricamento delle tabelle, è stata avviata la fase di analisi tramite SQL, utilizzando il file ANALYSIS_QUERIES.sql. In questa fase **sono state scritte query per interrogare il database** e ottenere risultati aggregati utili all'interpretazione del dataset.

Le query SQL sono state organizzate in diverse aree di analisi:

1. andamento delle recensioni nel tempo;

2. analisi delle nazionalità dei recensori;

3. performance degli hotel;

4. distribuzione geografica delle recensioni;

5. relazione tra lunghezza delle recensioni e punteggio;

6. confronto tra punteggi medi e caratteristiche delle recensioni.

L'utilizzo di SQL ha permesso di lavorare direttamente sul database relazionale e di ottenere risultati sintetici tramite operazioni di selezione, filtro, raggruppamento, ordinamento e join tra tabelle.

In particolare, sono state utilizzate query con GROUP BY[7] per aggregare le recensioni per anno, mese, nazionalità e città; query con ORDER BY[8] per individuare le categorie con valori più elevati; e query con JOIN per collegare le recensioni alle informazioni degli hotel e dei recensori.

Questa fase ha permesso di ottenere i primi risultati quantitativi dell'analisi, successivamente visualizzati con pandas importando Matplotlib per la creazione dei grafici.

[7].Se le eseguiamo nel nostro database di esempio, otteniamo dunque gli stessi risultati. La clausola GROUP BY serve a specificare quali sono i campi su cui effettuare i raggruppamenti: il motore di query, per ogni riga esaminerà tali campi e la classificherà nel gruppo corrispondente.

[8] Con la query ORDER BY è possibile organizzare i risultati di ricerca delle query di dati, in ordine crescente o decrescente. Ordinando i dati in righe e colonne tabella di destinazione è possibile aumentare la chiarezza e la leggibilità. In questo modo è possibile ottimizzare e velocizzare le analisi dei dati e le query su record di dati complessi.

# 3. RISULTATI DELL'ANALISI

In questa sezione vengono presentati i principali risultati ottenuti attraverso le query SQL, le analisi con pandas e le visualizzazioni realizzate con Matplotlib.

I risultati sono organizzati per aree tematiche: andamento temporale delle recensioni, nazionalità dei recensori, distribuzione geografica, performance degli hotel, relazione tra lunghezza delle recensioni e punteggio, e correlazioni tra variabili numeriche.

L'obiettivo di questa sezione è interpretare i dati emersi dall'analisi, evidenziando i principali pattern presenti nel dataset e collegandoli al comportamento dei recensori e alla performance degli hotel europei

## 3.1 Andamento temporale delle recensioni

La prima analisi riguarda la distribuzione delle recensioni nel tempo. Attraverso le variabili Review_Year e Review_Month, create durante la fase di pulizia, **è stato possibile osservare come il numero di recensioni varia nei diversi anni e mesi presenti nel dataset**.

Figura 1.1 – Line Plot recensioni per mese

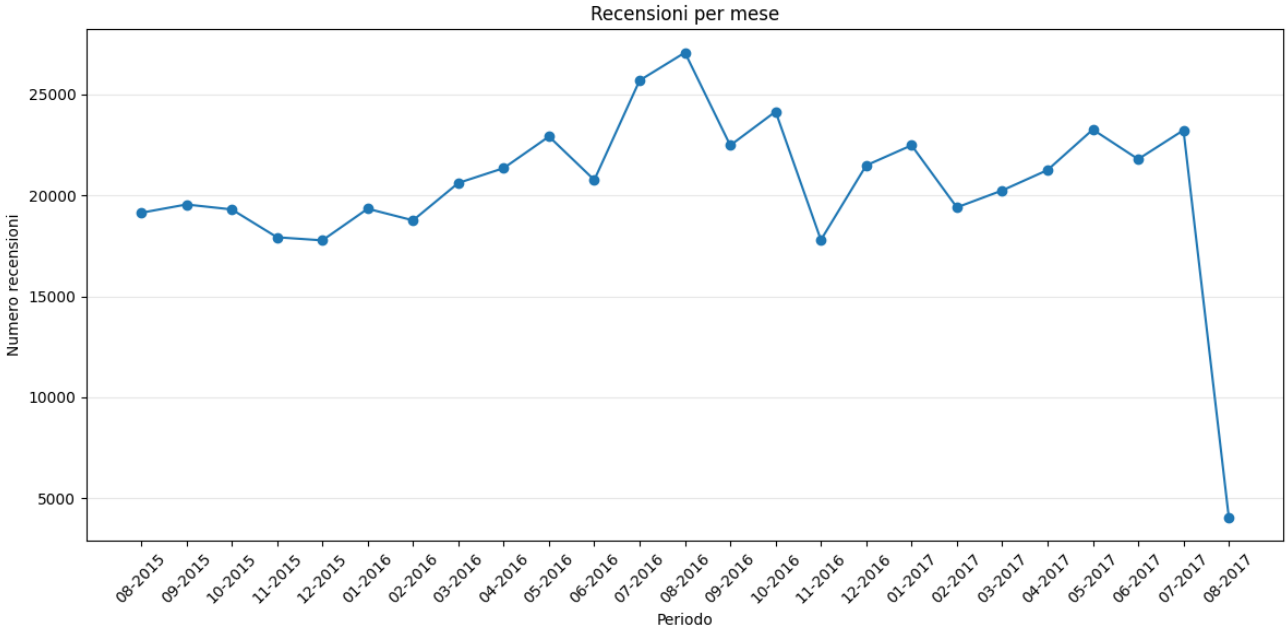


L'analisi mensile permette di osservare con maggiore dettaglio l'evoluzione delle recensioni. Alcuni mesi presentano un numero più alto di recensioni rispetto ad altri, probabilmente anche per effetto della stagionalità turistica. Nei periodi di maggiore affluenza, infatti, aumenta il numero di soggiorni e di conseguenza anche il numero di recensioni pubblicate.

Figura 2.2 – Line plot recensioni per anno

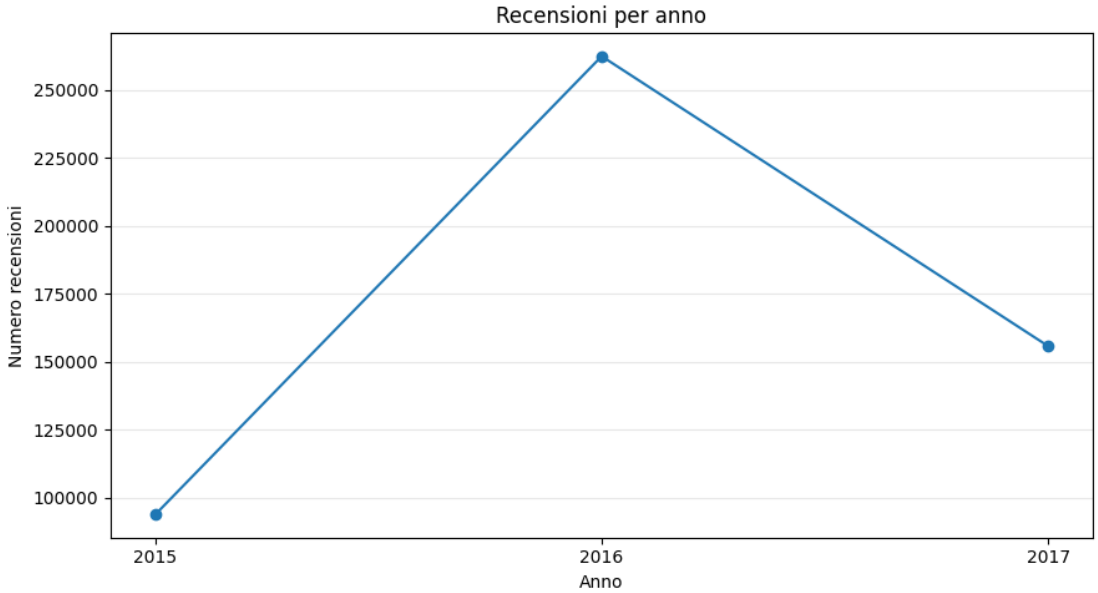

Dal grafico annuale emerge che le recensioni non sono distribuite in modo uniforme nel periodo considerato. Il 2016 risulta l'anno con il maggior numero di recensioni, mentre il 2015 presenta un volume inferiore perché il dataset copre solo una parte dell'anno. Anche il 2017 mostra un numero minore di recensioni rispetto al 2016.

## 3.2 Nazionalità dei recensori

Una seconda area di analisi riguarda la nazionalità dei recensori. Questa variabile è importante perché permette di capire da quali paesi provengono principalmente gli utenti che hanno recensito gli hotel presenti nel dataset.

Figura 3.1 – Bar chart top 10 nazionalità dei recensori

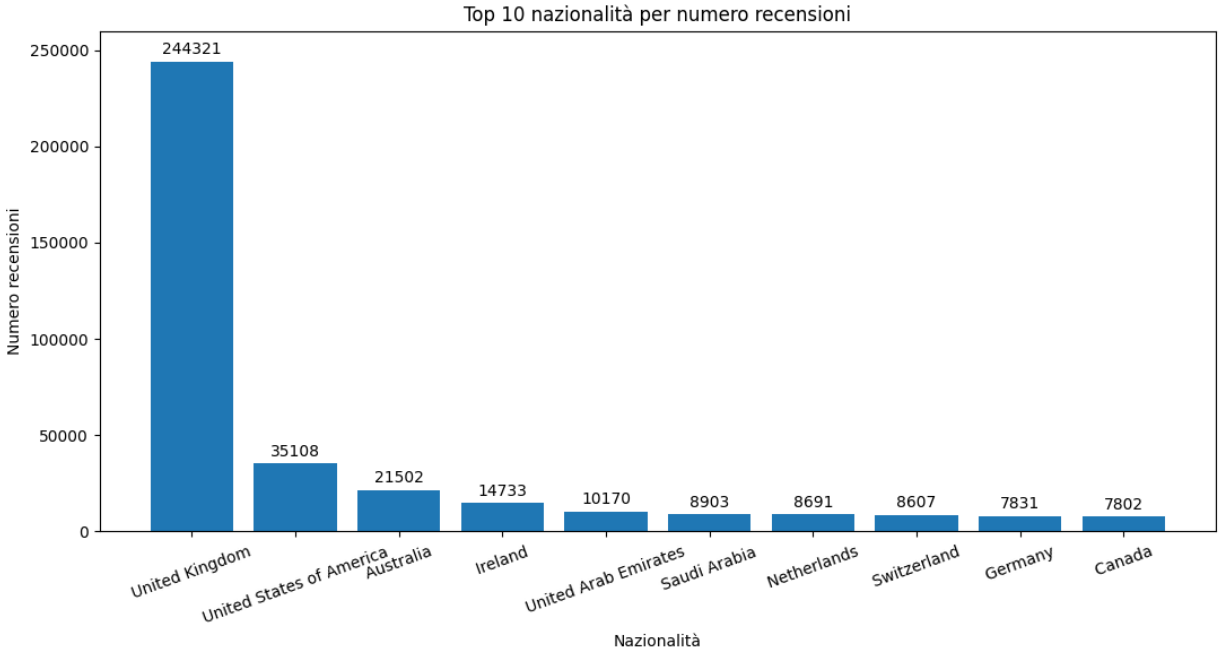


Il grafico mostra una forte **prevalenza dei recensori provenienti dal Regno Unito**. Questa nazionalità rappresenta il gruppo più numeroso all'interno del dataset e incide in modo significativo sui risultati complessivi dell'analisi. Seguono, con un numero di recensioni molto più basso, i recensori provenienti da Stati Uniti, Australia, Irlanda ed

Emirati Arabi Uniti. Questa distribuzione mostra che il dataset non è perfettamente bilanciato tra le nazionalità, ma risulta fortemente influenzato dalla componente britannica.

La presenza così elevata dei recensori britannici può essere collegata anche alla forte rappresentazione di Londra nel dataset. Infatti, molti hotel analizzati si trovano nel Regno Unito, e questo può aver favorito una maggiore presenza di recensioni da parte di utenti britannici.

Dal punto di vista interpretativo, questo risultato è importante perché mostra che il dataset non è perfettamente bilanciato tra le diverse nazionalità. Di conseguenza, le medie generali dei punteggi possono essere influenzate dal comportamento valutativo dei recensori UK.

Per approfondire l'analisi sulle nazionalità, nel file ANALYSIS_QUERIES.sql è stata inserita anche una query specifica per confrontare il comportamento dei recensori del Regno Unito con quello degli altri recensori. La query utilizza una condizione CASE WHEN per dividere le recensioni in due gruppi: "UK", quando la nazionalità del recensore è United Kingdom, e "Altre nazionalità" per tutti gli altri casi.

Questo confronto è stato utile per verificare se i recensori britannici assegnassero punteggi medi diversi rispetto al resto degli utenti. Dai risultati emerge che i recensori UK presentano uno score medio leggermente più alto rispetto agli altri recensori: 8,49 contro 8,31.

La differenza non è molto ampia, ma risulta significativa dal punto di vista interpretativo, perché i recensori del Regno Unito rappresentano il gruppo più numeroso del dataset. Di conseguenza, anche una differenza contenuta nel loro comportamento valutativo può incidere sui risultati complessivi dell'analisi.

## 3.3 Performance città e hotel

La terza area di analisi riguarda la performance delle città e degli hotel presenti nel dataset. In questa sezione sono stati considerati sia il numero di recensioni sia lo score medio, in modo da distinguere tra volume di recensioni e qualità percepita.

Figura 3.2 – Bar chart top città per numero di recensioni

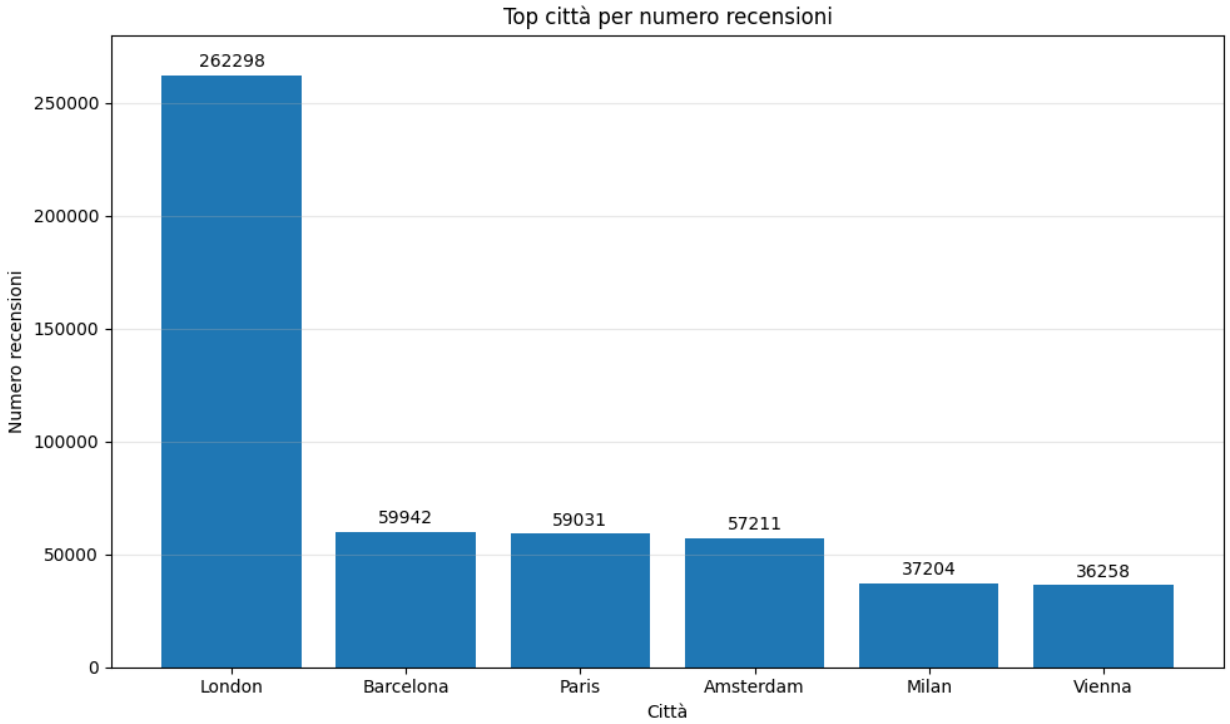


La Figura 3.2 mostra le città con il maggior numero di recensioni presenti nel dataset. Dal grafico emerge una **forte concentrazione delle recensioni nella città di Londra**, che risulta nettamente più rappresentata rispetto alle altre città europee.

Seguono città come Barcellona, Parigi, Amsterdam, Milano e Vienna, ma con un numero di recensioni nettamente inferiore rispetto a Londra.

Il dato è coerente anche con la prevalenza dei recensori del Regno Unito osservata nella sezione precedente. La forte presenza di Londra contribuisce infatti a spiegare il peso elevato delle recensioni provenienti da utenti britannici.

Dal punto di vista interpretativo, questo risultato è importante perché mostra che il numero di recensioni misura soprattutto il volume e la visibilità delle strutture, ma non necessariamente la loro qualità percepita. Per questo motivo, oltre alla quantità di recensioni, è stato analizzato anche lo score medio per città.

Figura 3.3 – Bar chart score medio per top città

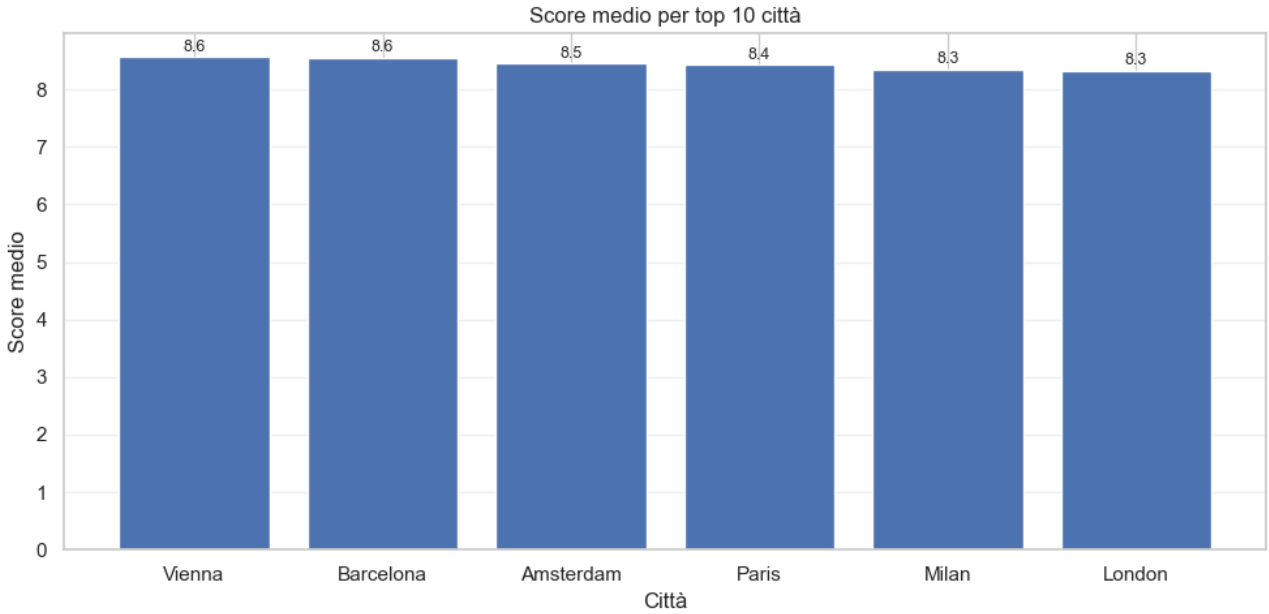


La Figura 3.3 mostra lo score medio delle principali città presenti nel dataset. Questo grafico consente di confrontare la valutazione media ricevuta dagli hotel nelle diverse città, indipendentemente dal numero totale di recensioni.

Dal grafico emerge che le differenze tra le città sono contenute: tutti i valori si collocano tra circa 8,3 e 8,6, indicando una valutazione media generalmente positiva degli hotel analizzati.

**La città con lo score medio più alto risulta Vienna**, con un valore pari a circa 8,6, seguita da Barcellona e Amsterdam. Parigi presenta uno score medio leggermente inferiore, pari a circa 8,4, mentre Milano e Londra registrano valori intorno a 8,3.

Dal confronto **emerge che le città con il maggior numero di recensioni non coincidono necessariamente con quelle che presentano lo score medio più alto**. Londra, pur essendo la città più rappresentata per volume di recensioni, non risulta necessariamente la città con la migliore valutazione media.

Questo risultato evidenzia una distinzione importante tra quantità di recensioni e performance qualitativa. Una città può avere un numero molto elevato di recensioni perché ospita molte strutture o perché registra un forte volume turistico, ma questo non implica automaticamente una maggiore soddisfazione media dei clienti.

Oltre allo score medio per città, è stata analizzata anche la distribuzione delle recensioni a livello di ogni singolo hotel. A supporto di questa parte dell'analisi, nel file ANALYSIS_QUERIES.sql è stata eseguita una query di join tra le tabelle hotels e reviews, con l'obiettivo di contare il numero di recensioni associate a ciascun hotel e ordinare le strutture in base al volume di recensioni ricevute.

Dai risultati emerge che gli hotel con il maggior numero di recensioni sono localizzati prevalentemente a Londra. Tra le strutture più recensite compaiono, ad esempio, il Britannia International Hotel Canary Wharf, lo Strand Palace Hotel e il Park Plaza Westminster Bridge London. Questo risultato conferma quanto già osservato nell'analisi per città: Londra domina il dataset non solo per numero complessivo di recensioni, ma anche per la presenza di singoli hotel con un volume molto elevato di recensioni.

Dal punto di vista interpretativo, il numero di recensioni non rappresenta necessariamente un indicatore diretto di qualità, ma piuttosto un indicatore di visibilità, presenza nel dataset e intensità dell'attività recensoria. Per valutare in modo più completo la performance delle strutture è quindi necessario considerare anche lo score

medio e il confronto tra i punteggi assegnati dai recensori e la valutazione media complessiva dell'hotel.

L'analisi sulla performance di città e hotel mostra che Londra occupa una posizione centrale per volume di recensioni, mentre il confronto degli score medi evidenzia che le città più recensite non coincidono necessariamente con quelle che ottengono le valutazioni migliori. Questo conferma la distinzione tra quantità di recensioni e qualità percepita.

## 3.4 Correlazione score e lunghezza

La quarta area di analisi riguarda la relazione tra il punteggio assegnato dai recensori e la lunghezza delle recensioni. Per questa analisi è stata utilizzata la variabile derivata total_review_length, creata durante la fase di pulizia e preparazione del dataset.

L'obiettivo di questa sezione è verificare se la quantità di parole utilizzate dagli utenti nelle recensioni sia collegata al punteggio assegnato all'hotel. In particolare, l'analisi permette di osservare se le recensioni più lunghe siano associate a valutazioni più basse, medie o alte.

Figura 3.4 – Distribuzione della lunghezza delle recensioni per categoria di score

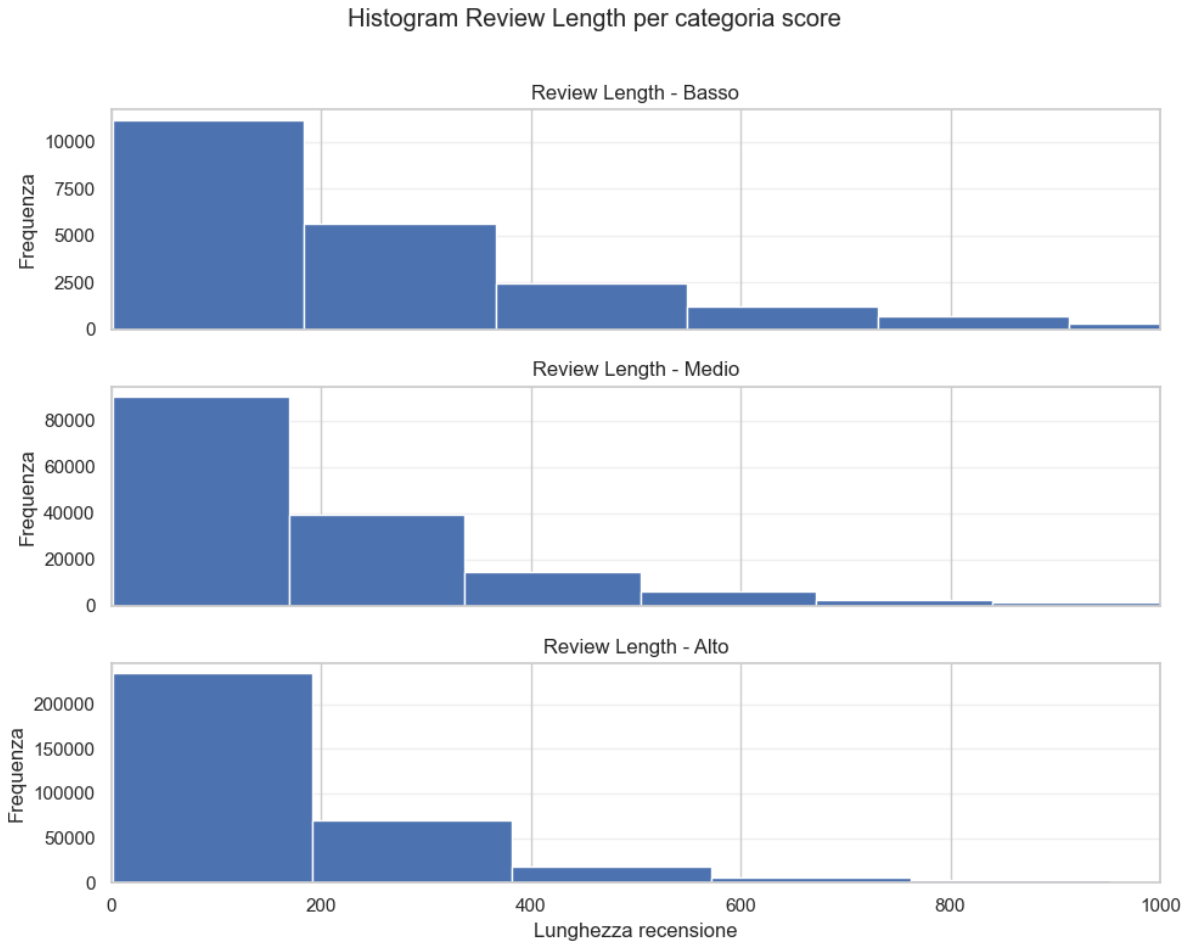


La Figura 3.4 mostra la distribuzione della lunghezza delle recensioni in base alla categoria di punteggio assegnato dal recensore. Le recensioni sono state suddivise in tre gruppi principali: recensioni con score basso, recensioni con score medio e recensioni con score alto.

Dall'analisi **emerge che le recensioni con punteggio più basso tendono a essere mediamente più lunghe rispetto a quelle con punteggio alto**. Questo risultato suggerisce che i clienti meno soddisfatti sono più propensi a descrivere in modo dettagliato la propria esperienza, probabilmente per spiegare i problemi riscontrati durante il soggiorno.

Al contrario, le recensioni con punteggio alto risultano generalmente più brevi e sintetiche. Questo può indicare che gli utenti soddisfatti tendono a lasciare commenti più diretti, mentre gli utenti insoddisfatti forniscono spiegazioni più articolate.

Figura 3.5 - Scatter plot Review Length vs Reviewer Score

La Figura 3.5 mostra la relazione tra la lunghezza della recensione e il punteggio assegnato dal recensore, distinguendo le principali nazionalità presenti nel dataset: United Kingdom, United States of America e Australia.

Nel grafico si osserva che la maggior parte delle recensioni si concentra su punteggi medio-alti, soprattutto tra 8 e 10, indipendentemente dalla nazionalità del recensore. Questo conferma una tendenza generale verso valutazioni positive degli hotel analizzati.

Per quanto riguarda la lunghezza delle recensioni, la maggior parte dei punti si concentra nelle fasce più basse, quindi le recensioni brevi risultano più frequenti. Tuttavia, sono presenti anche recensioni molto lunghe, soprattutto nel gruppo United Kingdom, che è anche il gruppo più numeroso all'interno del dataset.

Dal grafico non emerge una correlazione lineare forte tra lunghezza della recensione e punteggio assegnato. I punti risultano infatti abbastanza dispersi. Tuttavia, si può osservare che alcune recensioni più lunghe sono associate a punteggi più bassi o intermedi, confermando l'ipotesi che gli utenti meno soddisfatti tendano a scrivere commenti più dettagliati.

Il confronto tra nazionalità mostra inoltre l'United Kingdom presenta una maggiore dispersione, sia per numero di osservazioni sia per varietà dei punteggi. I gruppi United States of America e Australia risultano invece meno numerosi e più concentrati su punteggi elevati.

Nel complesso, la figura suggerisce che la lunghezza della recensione può essere utile per interpretare meglio il livello di soddisfazione del cliente, ma non è sufficiente da sola a spiegare il punteggio. Per questo motivo, è necessario leggerla insieme ad altre variabili, come il contenuto positivo o negativo della recensione e lo score assegnato.

# 4. CONCLUSIONI

L'analisi del dataset ha permesso di individuare una serie di insight rilevanti per la comprensione del comportamento dei clienti e per il supporto alle decisioni strategiche nel settore turistico, con particolare riferimento alle attività di revenue management.

In primo luogo, dall'analisi temporale emerge che le recensioni non risultano distribuite in modo uniforme nel tempo, ma presentano variazioni che possono essere associate ai cambiamenti nel numero di recensioni durante l'anno e all'aumento delle prenotazioni. Questo aspetto è particolarmente rilevante per un Revenue Manager, in quanto consente di collegare l'andamento delle recensioni ai periodi di maggiore affluenza, alle politiche di prezzo e alle strategie promozionali adottate dalle strutture.

Per quanto riguarda il profilo dei recensori, alcune nazionalità si distinguono sia per il volume di recensioni sia per il punteggio medio assegnato. In particolare, i recensori provenienti dal Regno Unito risultano tra i più attivi e tendono a fornire valutazioni mediamente elevate.

Questo suggerisce la presenza di possibili differenze culturali nella percezione del servizio e nella propensione a lasciare feedback positivi, evidenziando l'importanza di segmentare la clientela anche in base alla provenienza geografica. Per un Revenue Manager, tali informazioni possono essere utilizzate per sviluppare strategie di comunicazione e marketing più mirate, oltre che per interpretare correttamente i punteggi medi delle strutture.

L'analisi delle performance delle città e delle strutture evidenzia inoltre differenze significative nella qualità percepita. Londra emerge come città dominante per volume di recensioni, ma non coincide con la città con lo score medio più alto. Questo conferma che la quantità di recensioni misura soprattutto la visibilità delle strutture, mentre la qualità percepita deve essere valutata attraverso lo score medio. Questo può riflettere non solo la qualità dell'offerta ricettiva, ma anche fattori esterni come infrastrutture, servizi e attrattività turistica. Tali evidenze possono supportare decisioni strategiche

relative al posizionamento delle strutture, alla definizione dei prezzi e al miglioramento dei servizi offerti.

Un ulteriore aspetto analizzato riguarda la relazione tra la lunghezza delle recensioni e il punteggio assegnato. I risultati mostrano chiaramente l'assenza di una correlazione significativa tra queste due variabili. La lunghezza del testo, infatti, non rappresenta un indicatore affidabile del livello di soddisfazione del cliente, poiché recensioni sia brevi che lunghe possono essere associate a punteggi elevati o bassi. Questo implica che, per ottenere informazioni realmente utili, è necessario considerare il contenuto qualitativo delle recensioni e non soltanto la loro dimensione.

I risultati ottenuti, evidenziano come l'analisi dei dati delle recensioni online possa fornire informazioni strategiche di grande valore per il settore turistico. In particolare, tali insight possono essere utilizzati per migliorare l'esperienza del cliente, ottimizzare la gestione della reputazione online e supportare le decisioni di pricing e posizionamento delle strutture.

Infine, possibili sviluppi futuri dell'analisi potrebbero includere l'applicazione di tecniche di sentiment analysis per approfondire il contenuto testuale delle recensioni, oppure l'utilizzo di modelli predittivi per stimare il comportamento futuro dei clienti e l'andamento dei punteggi.

## 4.1 Consigli operativi per il cliente

Dall'analisi emerge che, per un hotel, la reputazione online è un elemento centrale. Nelle città più visitate, dove gli utenti confrontano rapidamente molte strutture prima di prenotare, avere un buon numero di recensioni e un punteggio medio positivo può fare davvero la differenza. Per questo motivo, **il cliente dovrebbe controllare con regolarità l'andamento dei propri punteggi e confrontarli con quelli degli hotel concorrenti nella stessa città**. Questo permetterebbe di capire meglio dove la struttura è forte e dove, invece, potrebbe migliorare.

Un aspetto importante è non fermarsi solo al voto numerico lasciato dal cliente. Il Reviewer_Score dà sicuramente un'indicazione generale, ma spesso sono il contenuto e la lunghezza delle recensioni a spiegare davvero cosa ha funzionato e cosa no. In particolare, recensioni negative molto lunghe possono segnalare problemi più sentiti dal cliente, ad esempio legati alla pulizia, al comfort, alla posizione, ai servizi offerti o al rapporto qualità-prezzo. **Leggere e analizzare questi commenti aiuterebbe quindi l'hotel a intervenire in modo più mirato sui problemi più frequenti**.

Dal punto di vista commerciale, gli hotel con punteggi alti e molte recensioni hanno un vantaggio competitivo maggiore, perché trasmettono più fiducia ai potenziali clienti. In questi casi, la struttura potrebbe anche permettersi tariffe più alte nei periodi di maggiore domanda.

**Al contrario, se un hotel presenta punteggi più bassi o una forte differenza tra Average_Score e Reviewer_Score, sarebbe preferibile lavorare prima sulla qualità del servizio, invece di puntare subito su un aumento dei prezzi**. In conclusione, l'analisi delle recensioni non serve solo a descrivere cosa pensano i clienti, ma può diventare uno strumento utile per migliorare l'esperienza offerta, rafforzare la reputazione online e prendere decisioni più consapevoli anche dal punto di vista economico.

## 4.2 Limiti all'analisi

L'analisi è stata condotta utilizzando strumenti avanzati come Python (Pandas) e SQL, che hanno consentito una gestione efficiente del dataset e lo sviluppo di query e trasformazioni strutturate. Tuttavia, presenta alcuni limiti.

In primo luogo, **il dataset copre un periodo temporale limitato (2015–2017)** e non riflette eventuali cambiamenti più recenti nel comportamento degli utenti o nel settore turistico.

Inoltre, **i dati si basano su recensioni volontarie**, introducendo un possibile bias di selezione: gli utenti che lasciano recensioni potrebbero non rappresentare l'intera popolazione dei clienti.

Un ulteriore limite riguarda il tipo di analisi effettuata. Nonostante l'utilizzo di Python e SQL per la gestione e l'analisi dei dati, **l'approccio adottato è principalmente descrittivo**. Non sono stati applicati modelli statistici avanzati o tecniche di machine learning, che avrebbero potuto evidenziare relazioni più complesse tra le variabili.

Infine, l'analisi non approfondisce il contenuto testuale delle recensioni. L'assenza di tecniche di sentiment analysis limita la comprensione qualitativa delle opinioni espresse dagli utenti.

In conclusione, **questi limiti non compromettono la validità generale dell'analisi, ma aiutano a interpretarne i risultati in modo più consapevole**. L'utilizzo di Python e SQL ha permesso di costruire un processo solido di pulizia, organizzazione e analisi dei dati. Ulteriori approfondimenti potrebbero includere tecniche di sentiment analysis, modelli predittivi o analisi statistiche più avanzate, al fine di ottenere una comprensione più completa dei fattori che influenzano la soddisfazione degli utenti.